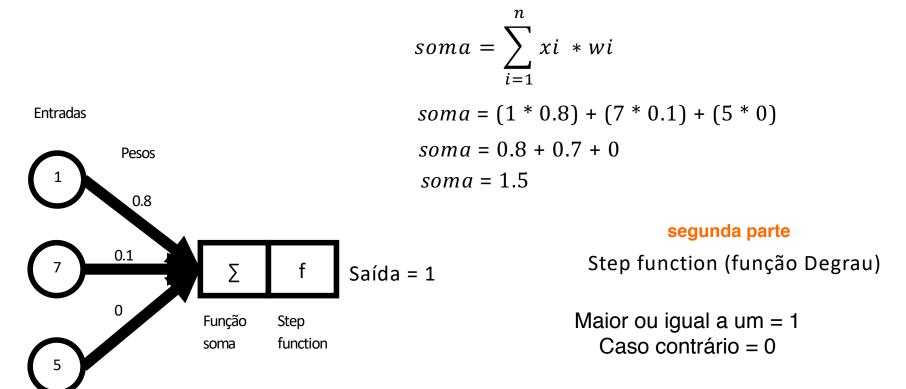
Redes Neurais

Prof. Luiz Alberto Bordignon

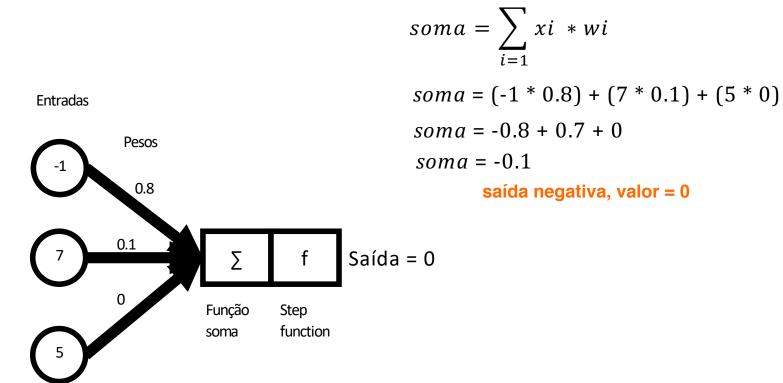
Neurônio artificial

primeira parte



processo básico de uma rede neural, multiplica as entradas pelos pesos, faz o somatório, e depois aplica uma função de ativação

Neurônio artificial

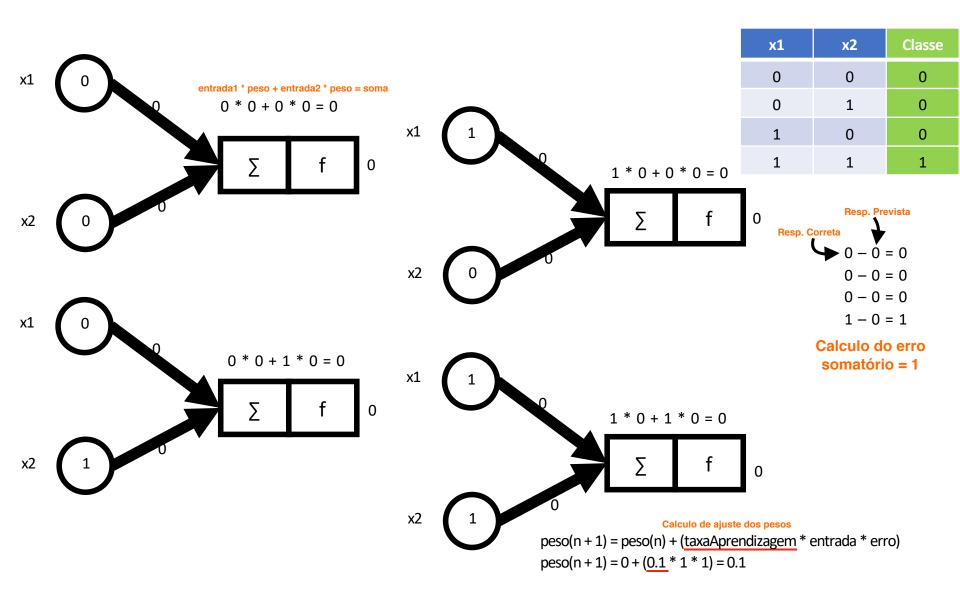


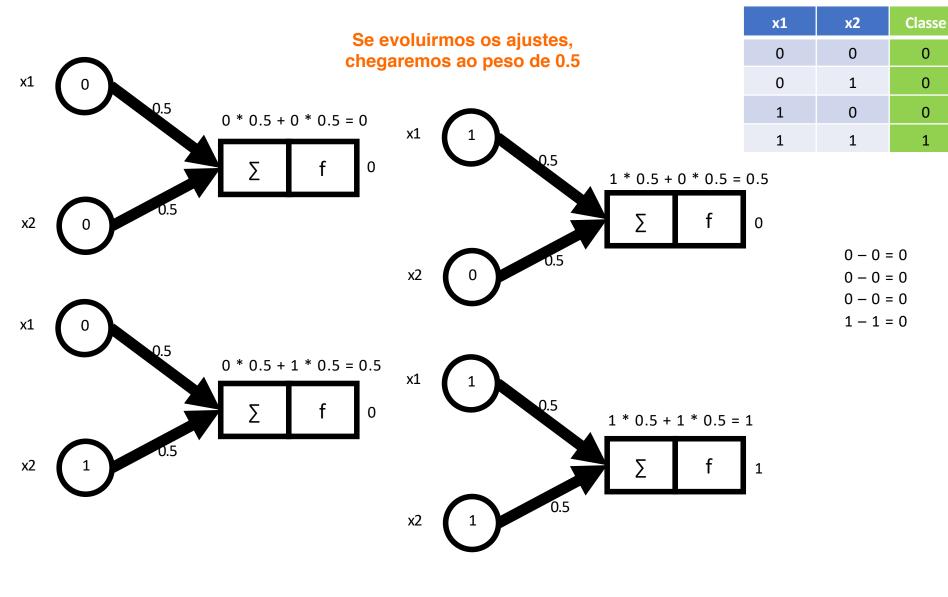
Exemplo

Operador E

x1	х2	Classe
0	0	0
0	1	0
1	0	0
1	1	1

Construir uma rede neural que consiga fazer a previsão do operador lógico AND. Fazer a rede aprender a calcular pesos, para conseguir prever os valores de saída do operador.



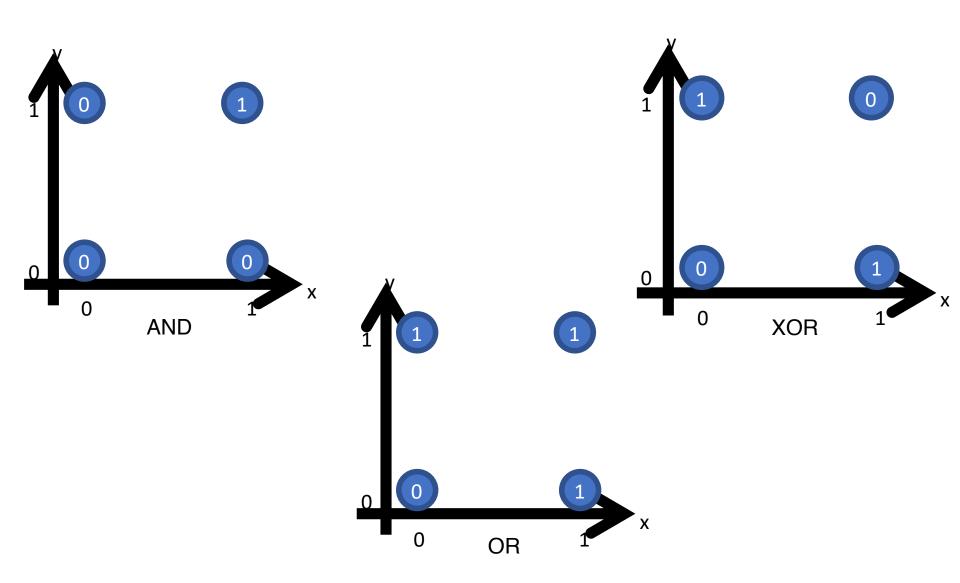


Objetivo

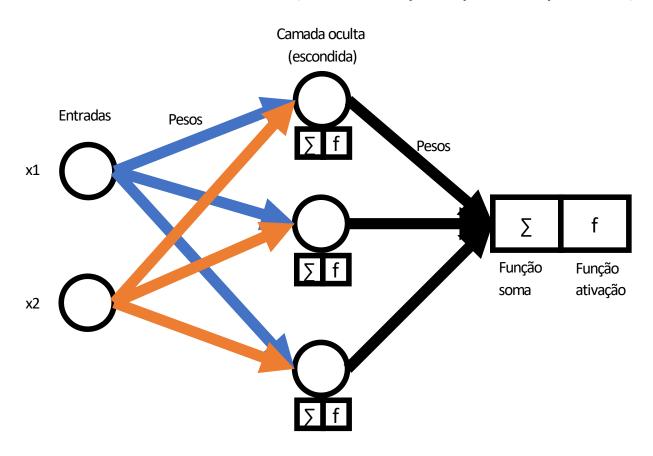
• A aprendizagem de uma rede neural é descobrir os melhores valores de peso para as camadas de neurônios.

Atividade

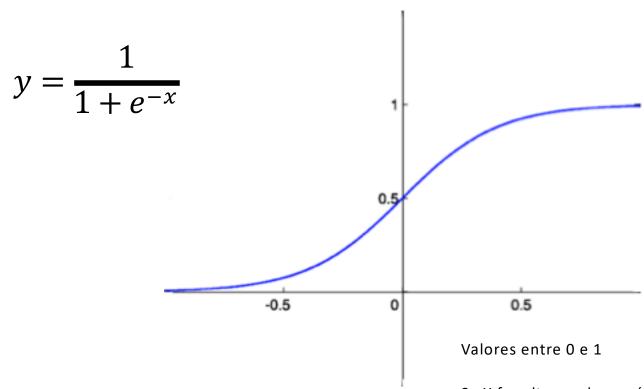
- Monte a tabela verdade dos operadores OR e XOR.
- Monte um rede neural que consiga prever os resultados desses operadores.
- Faça o calculo dos pesos dos neurônios.



Redes multicamada (multilayer perceptron)



Sigmoid (função sigmoide)

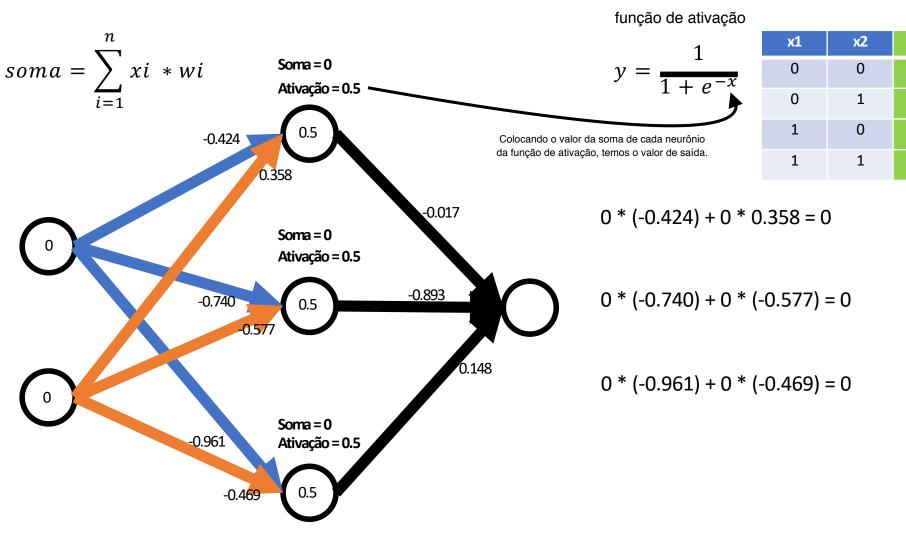


Se X for alto o valor será aproximadamente 1 Se X for pequeno o valor será aproximadamente 0 Não retorna valores negativos

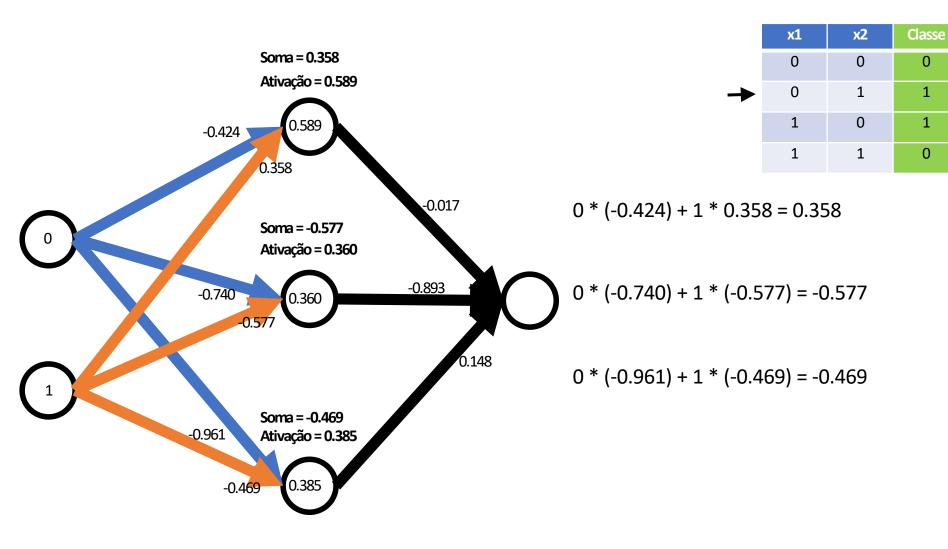
Operador XOR

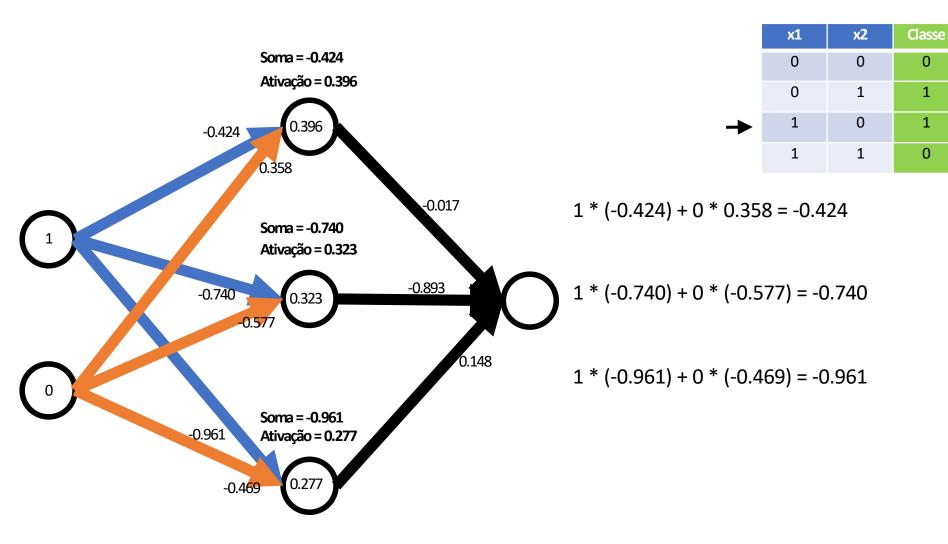
x1	х2	Classe
0	0	0
0	1	1
1	0	1
1	1	0

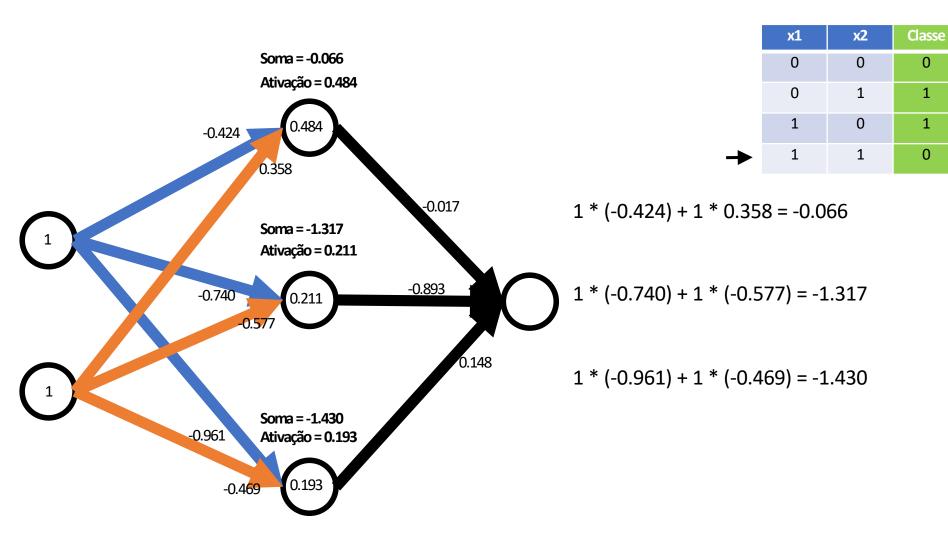
Cálculos camada entrada para camada oculta



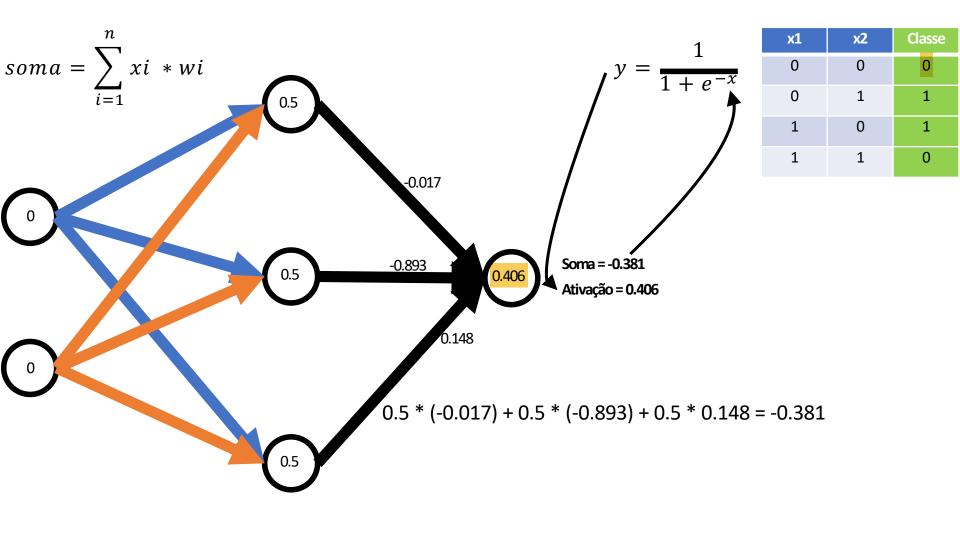
Os pesos são inseridos aleatóriamente

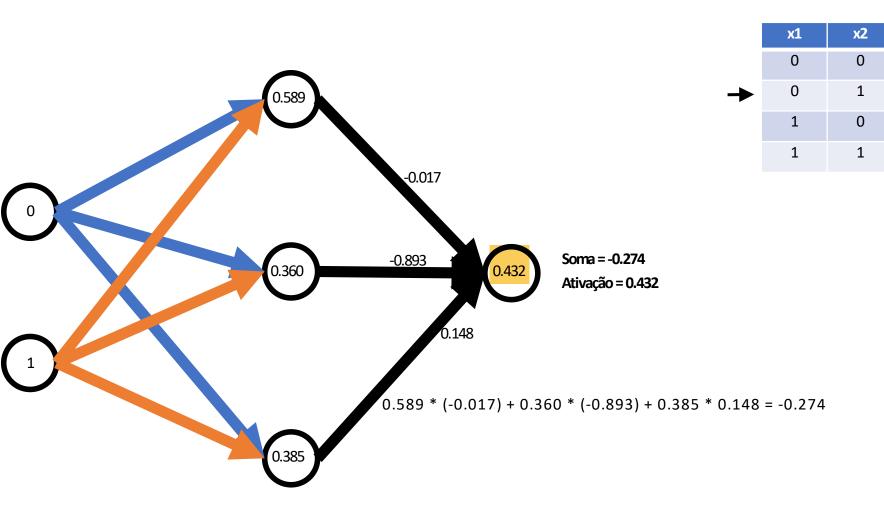


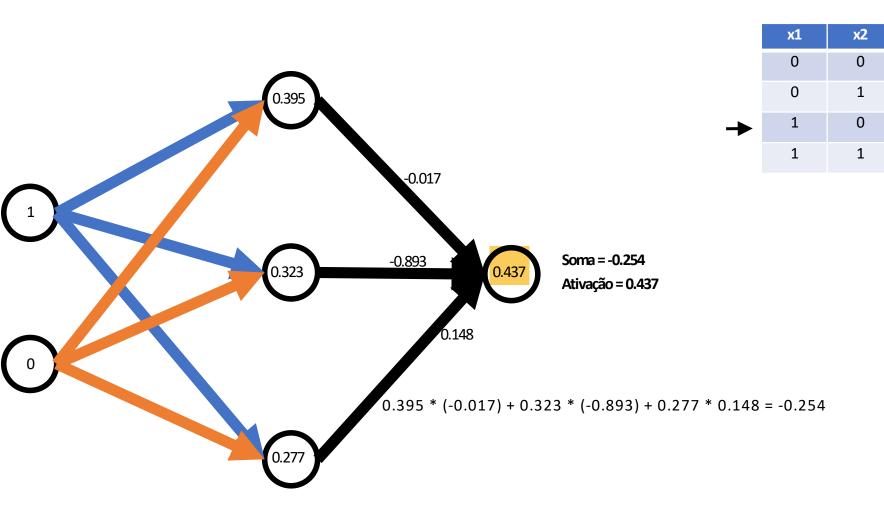


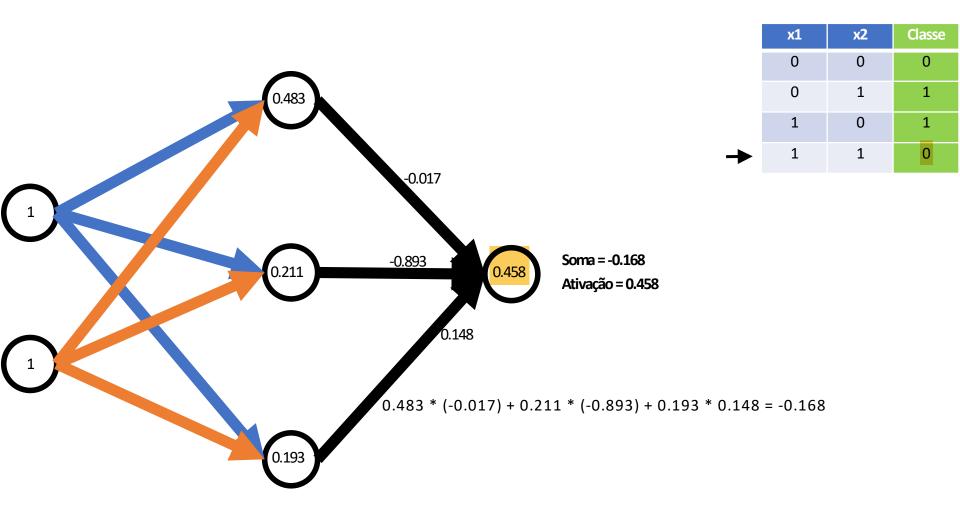


Cálculos camada oculta para camada de saída









Primeira rodada da rede esta pronta, ja temos os valores de previsão para os primeiros registros.

Erro

- Algoritmo mais simples
 - erro = respostaCorreta respostaCalculada

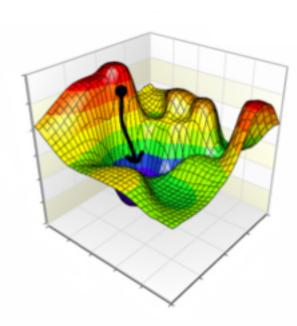
x1	х2	Classe	Calculado	Erro
0	0	0	0.406	-0.406
0	1	1	0.432	0.568
1	0	1	0.437	0.563
1	1	0	0.458	-0.458

Média absoluta = 0.49

Gradiente

loss function, ou função de perda min C(w1, w2 ... wn) Calcular a derivada parcial para mover para a direção do gradiente

Algoritmo que tenta encontrar o melhor valor de ajuste dos pesos



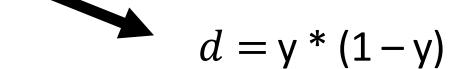
Gradiente

- Encontrar a combinação de pesos que o erro é o menor possível
- Gradiente é calculado para saber quanto ajustar os pesos

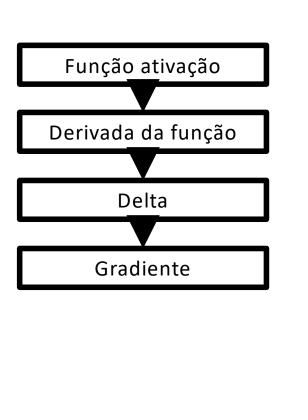


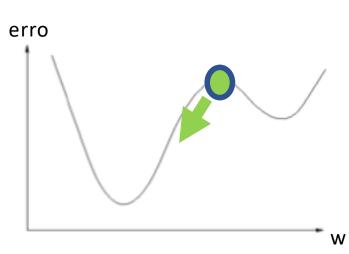
Gradiente (derivada)

$$y = \frac{1}{1 + e^{-x}}$$



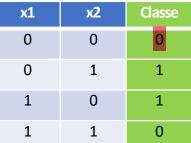
Cálculo do parâmetro Delta

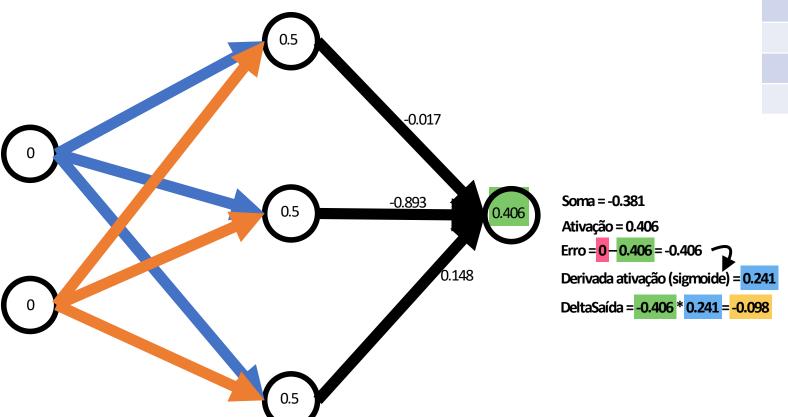




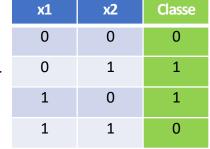
Delta camada saída

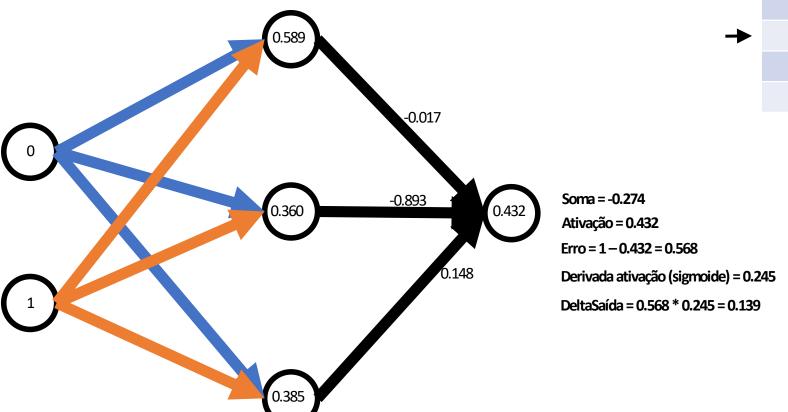
DeltaSaida = Erro * DerivadaSigmoide

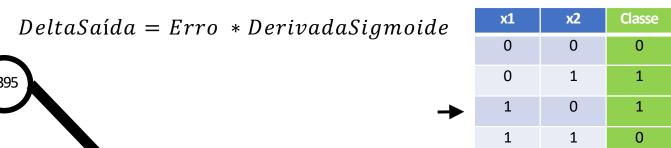


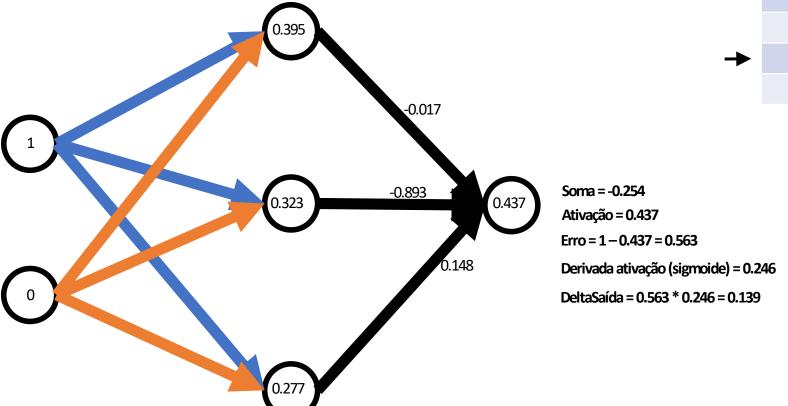


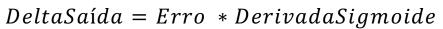


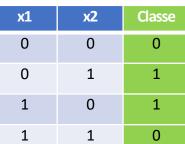


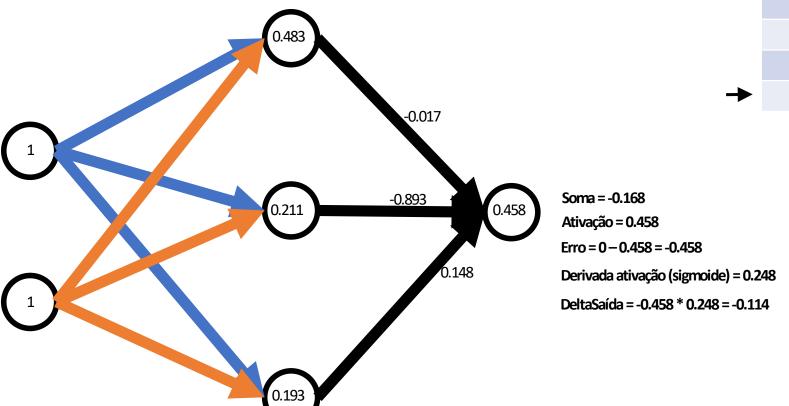






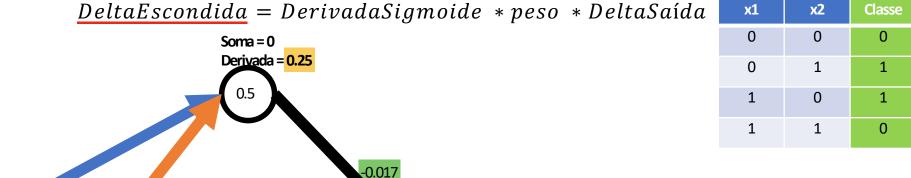


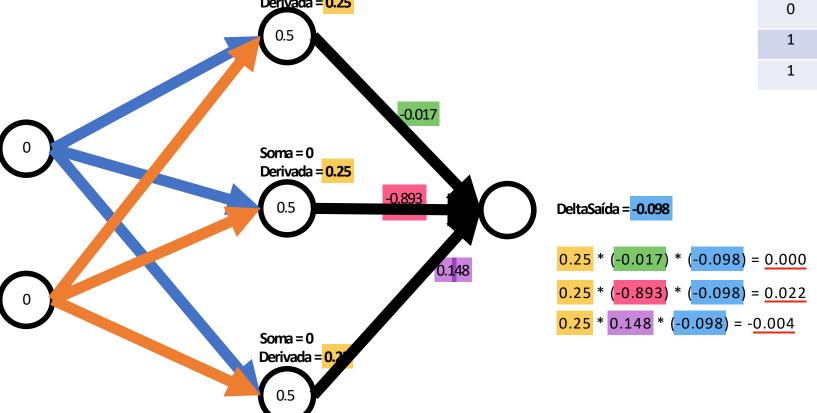


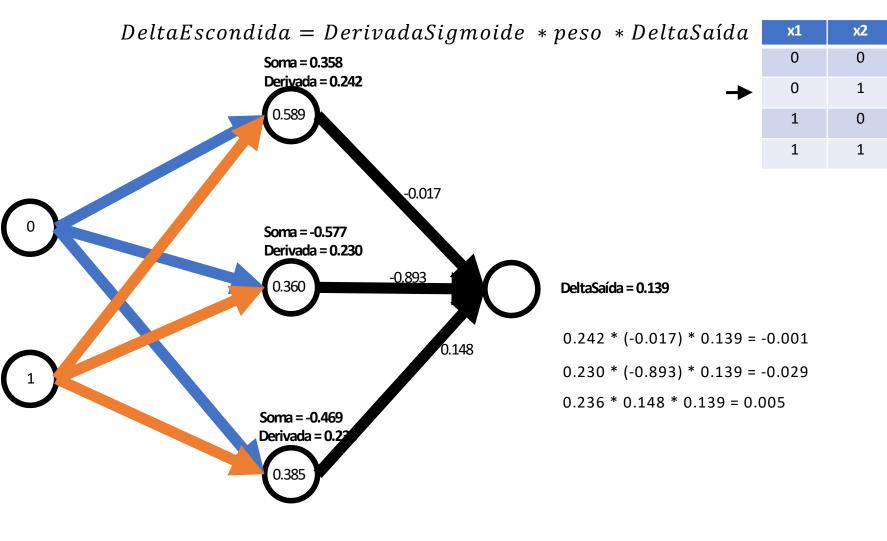


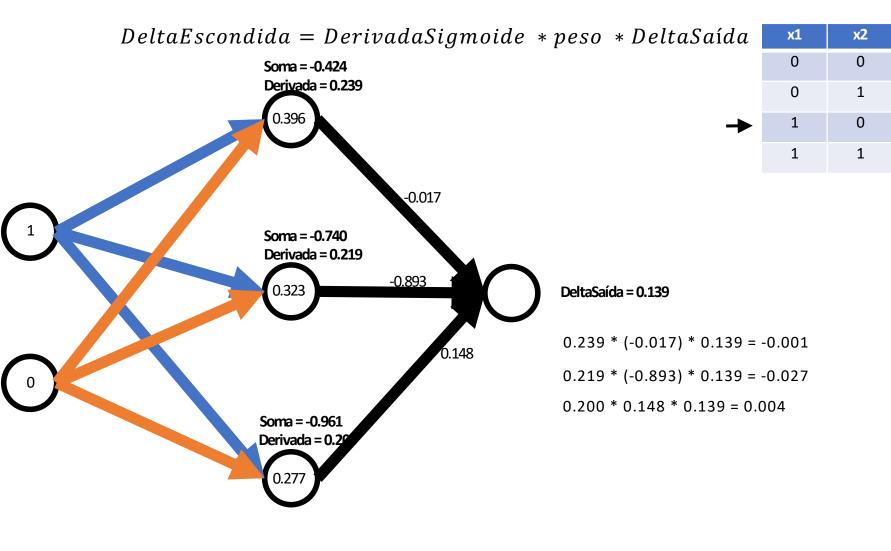
Delta camada escondida

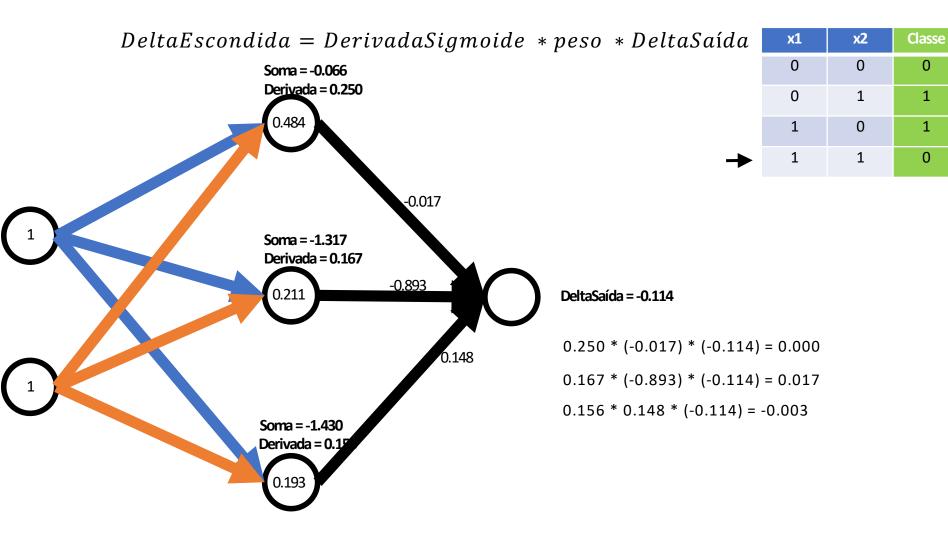




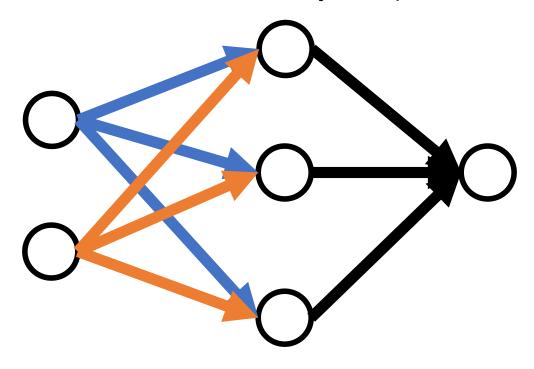








Formula de atualização dos pesos



próximo peso

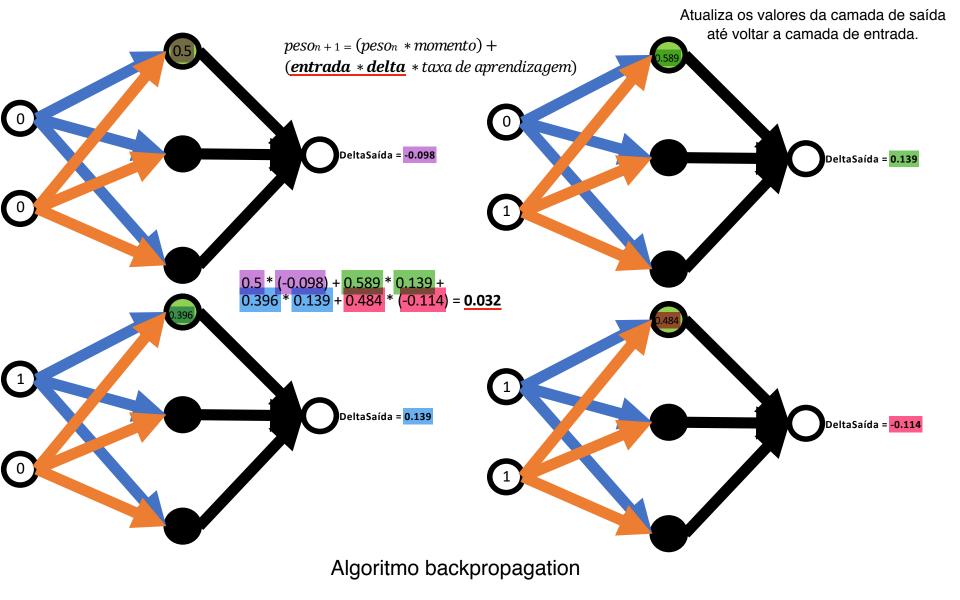
peso atual

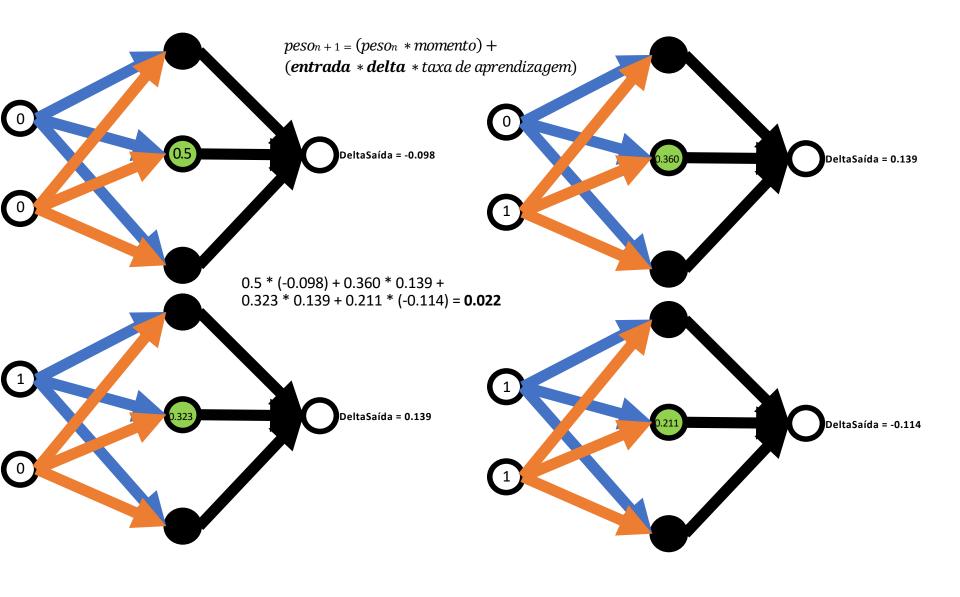
$$peson + 1 = (peson * momento) + (entrada * delta * taxa de aprendizagem)$$

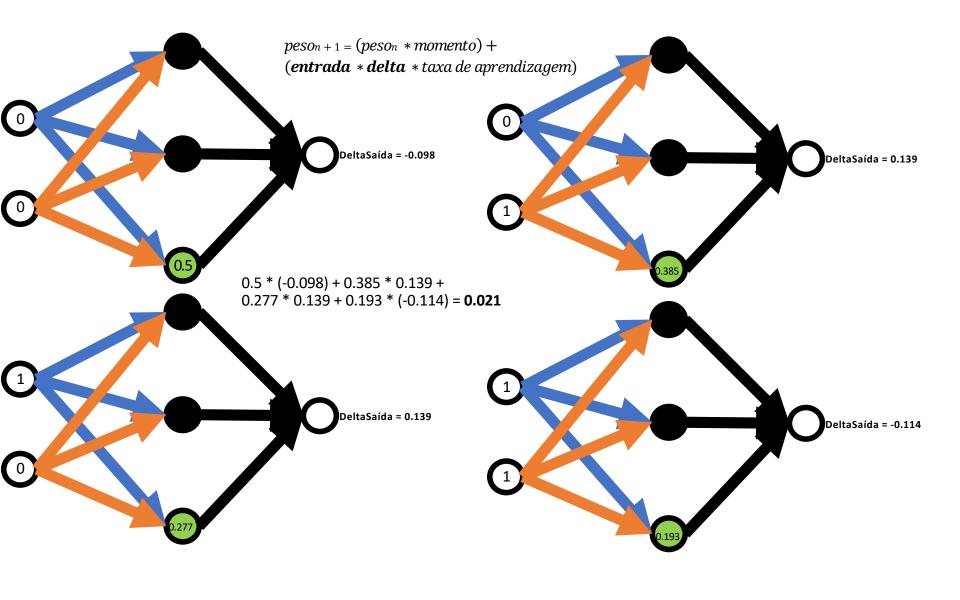
momento -> acelera o ajuste

Ajuste dos pesos da camada

oculta para a camada de saída







Ajuste dos pesos da camada oculta

```
Taxa de aprendizagem = 0.3
```

Momento = 1

Entrada x delta

- 0.032
- 0.022
- 0.021

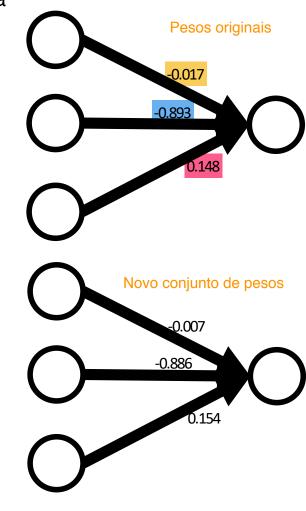
$$\frac{Peson + 1 = (peson * momento) +}{(entrada * delta} * taxa de aprendizagem)$$

Próximos pesos

$$(-0.017 * 1) + 0.032 * 0.3 = -0.007$$

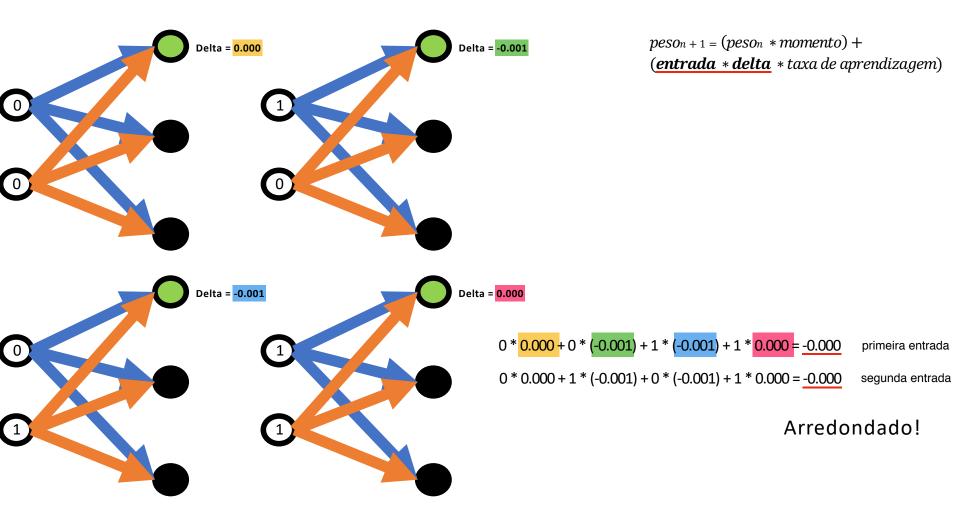
$$(-0.893 * 1) + 0.022 * 0.3 = -0.886$$

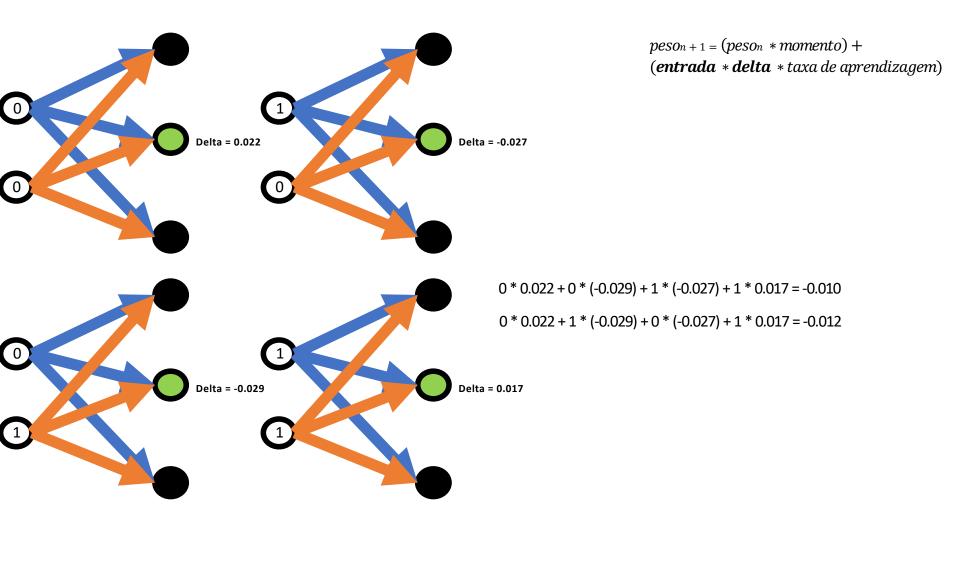
$$(0.148 * 1) + 0.021 * 0.3 = 0.154$$

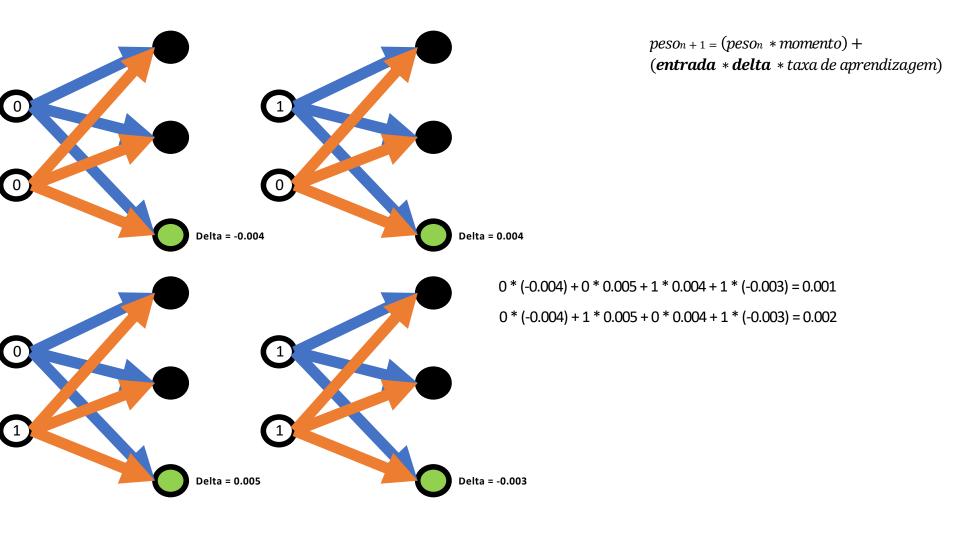


Ajuste dos pesos da camada de

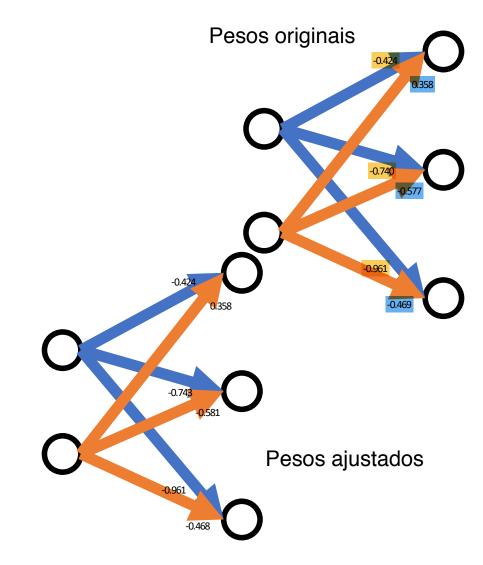
entrada para a camada oculta







```
Taxa de aprendizagem = 0.3
Momento = 1
Entrada x delta
-0.000 -0.010 0.001
-0.000 -0.012 0.002
Peson + 1 = (peson * momento) +
 (entrada * delta * taxa de aprendizagem)
(-0.424 * 1) + (-0.000) * 0.3 = -0.424
(0.358 * 1) + (-0.000) * 0.3 = 0.358
(-0.740 * 1) + (-0.010) * 0.3 = -0.743
(-0.577 * 1) + (-0.012) * 0.3 = -0.581
(-0.961 * 1) + 0.001 * 0.3 = -0.961
(-0.469 * 1) + 0.002 * 0.3 = -0.468
```



Com os valores do delta, faremos a atualização dos pesos

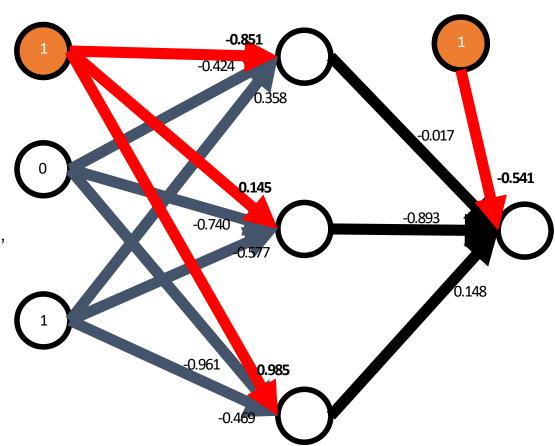
Bias

Valores diferentes mesmo se todas as entradas forem zero

Muda a saída com a unidade de bias

Normalmente os algoritmos de redes neurais, já tem essa camada de bias de forma transparente para a implementação

Ajuda a ajustar os valores de peso, dependendo das entradas.



Erro

- Algoritmo mais simples
 - erro = respostaCorreta respostaCalculada

x1	x2	Classe	Calculado	Erro
0	0	0	0.406	-0.406
0	1	1	0.432	0.568
1	0	1	0.437	0.563
1	1	0	0.458	-0.458

Mean square error (MSE) e Root mean square error (RMSE)

$$MSE = \frac{1}{N} \sum_{i=1}^{N} (f_i - y_i)^2 \qquad \qquad \text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^{N} (f_i \cdot o_i)^2}$$

x1	x2	Classe	Calculado	Erro
0	0	0	0.406	$(0-0.406)^2 = 0.164$
0	1	1	0.432	$(1 - 0.432)^2 = 0.322$
1	0	1	0.437	$(1-0.437)^2 = 0.316$
1	1	0	0.458	$(0 - 0.458)^2 = 0.209$

Soma = 1.011

MSE = 1.011 / 4 = 0.252 RMSE = 0.501

História do	Dívida	Garantias	Renda	Risco
3	1	1	1	100
2	1	1	2	100
2	2	1	2	010
2	2	1	3	100
2	2	1	3	001
2	2	2	3	001
3	2	1	1	100
3	2	2	3	010
1	2	1	3	001
1	1	2	3	001
1	1	1	1	100
1	1	1	2	010
1	1	1	3	001
3	1	1	2	100

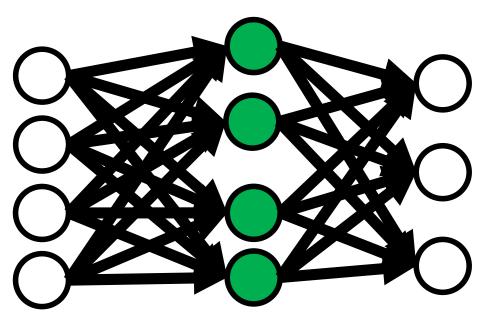
História do crédito	Dívida	Garantias	Renda anual	Risco
3	1	1	1	100
2	1	1	2	100
2	2	1	2	010
2	2	1	3	100
2	2	1	3	001
2	2	2	3	001
3	2	1	1	100
3	2	2	3	010
1	2	1	3	001
1	1	2	3	001
1	1	1	1	100
1	1	1	2	010
1	1	1	3	001
3	1	1	2	100

Calcula o erro para todos os registros e atualiza os pesos

Batch gradient descent

Calcula o erro para cada registro e atualiza os pesos

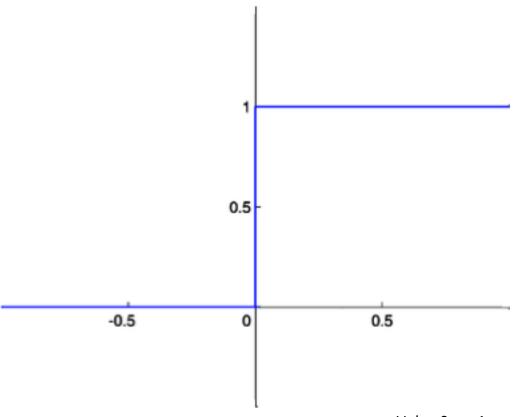
Stochastic gradient descent



Gradient descent

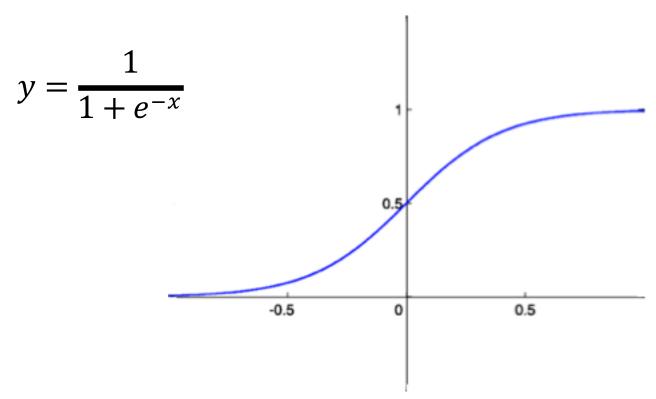
- Stochastic
 - Ajuda a prevenir mínimos locais (superfícies não convexas)
 - Mais rápido (não precisa carregar todos os dados em memória)
- Mini batch gradient descent
 - Escolhe um número de registros para rodar e atualizar os pesos

Step (função degrau)



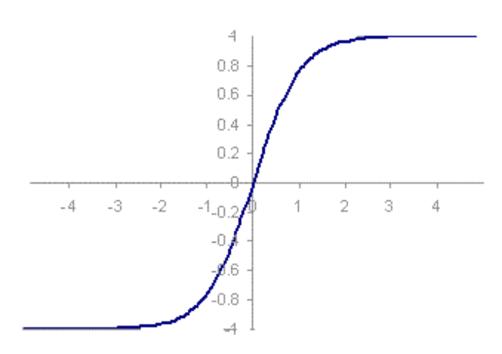
Valor 0 ou 1

Sigmoid (função sigmoide)



Hyperbolic tanget (função tangente hiperbólica)

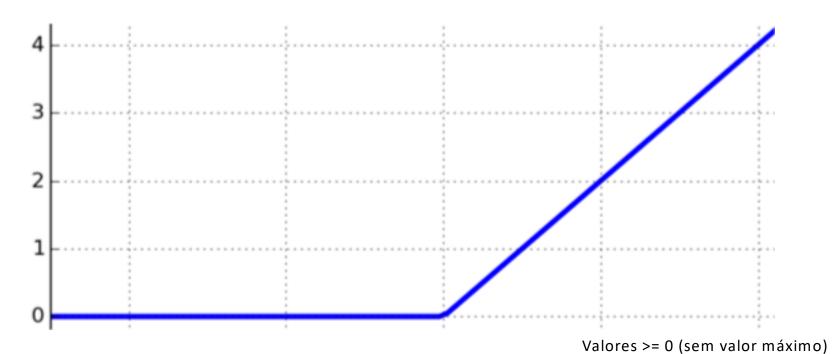
$$Y = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$



Valores entre -1 e 1

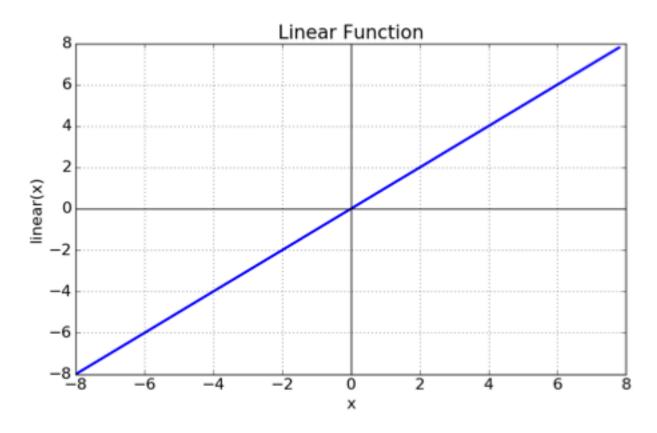
ReLU (rectified linear units)

$$Y = \max(0, x)$$



Problemas de visão computacional

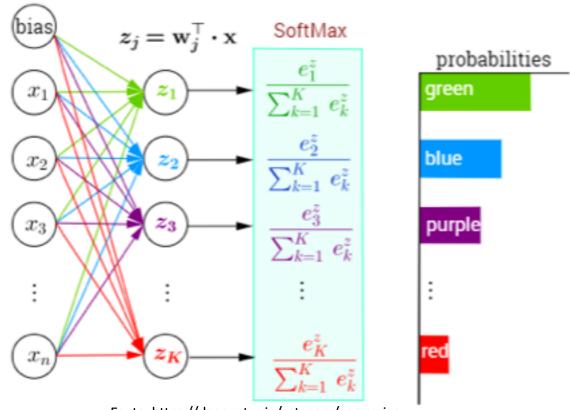
Linear



Problemas de regressão (previsão de números)

Softmax

$$Y = \frac{e(x)}{\sum e(x)}$$



Fonte: https://deepnotes.io/category/cnn-series

Atividade

- Utilizando qualquer tipo de linguagem, implementar as funções de ativação:
 - Step;
 - Sigmoid;
 - Hyperbolic tanget;
 - ReLU;
 - Softmax;
- Fazer teste com valores aleatórios.